

Churn Prediction

Réduire la perte clients par la Data Science

Classification binaire orientée ROI — Méthodologie CRISP-DM

-53%

clients perdus en 4 ans

70 000

observations dans le dataset

×2

lift de détection vs stratégie
actuelle

Projet Data Science — Télécommunications

Table des matières

1

Business Understanding

Objectifs, contraintes métier, formalisation de la loss

2

Data Understanding

Exploration des données, hypothèses, insights visuels

3

Data Preparation

Nettoyage, harmonisation, encodage, pipeline

4

Modélisation

Algorithmes, cross-validation, optimisation du seuil

5

Évaluation & Résultats

Comparaison avec la stratégie actuelle, lift, gain estimé

6

Recommandations & Limites

Plan d'action marketing, axes d'amélioration

1 — Business Understanding

Contexte & Problématique

■ Problème Business

L'entreprise a **perdu 53 % de ses clients** sur les 4 dernières années, représentant une perte de revenus majeure. L'enjeu est d'identifier les profils à risque et de réduire ce taux en optimisant les coûts marketing.

Objectifs du projet

- **Identifier** les facteurs explicatifs du churn.
- **Prédire** les clients susceptibles de partir (classification binaire).
- **Maximiser le ROI** de la stratégie de rétention marketing.
- **Livrer un outil de ciblage** utilisable directement par l'équipe marketing.

Formalisation de la fonction de perte

Plutôt que d'utiliser une métrique classique (accuracy, F1), le modèle est calibré sur une **fonction de perte monétaire** reflétant les coûts réels de chaque type d'erreur.

	Prédit : RESTE	Prédit : PART
Réalité : RESTE	✓ Vrai Négatif 0 €	✗ Faux Positif 25 €
Réalité : PART	✗ Faux Négatif 200 €	✓ Vrai Positif 0 €

Fonction de perte S

$$R_s(g) = 25 * nb(FP) + 200 * nb(FN)$$

Cette métrique représente la **perte moyenne en euros par client**. L'objectif est de trouver le prédicteur g qui minimise $R_s(g)$.

Contrainte humaine

■ Contrainte Opérationnelle

Capacité de traitement limitée à **500 appels/jour** (10 agents × 50 appels). Sur 10 000 clients, seul le **top 5%** peut être contacté par téléphone. Le modèle doit donc concentrer les vrais churners dans ce top 5%.

200 €

Coût d'un FN (churner manqué)

25 €

Coût d'un FP (offre à tort)

5%

Budget appels (top prioritaire)

75%

Recall cible contrainte métier

2 — Data Understanding

Description du dataset

70 000	21	26%	0
Observations clients	Features disponibles	Taux de churn (déséquilibre)	Doublons détectés

Variables disponibles

Démographie	gender, SeniorCitizen, Partner, Dependents
Compte	tenure, Contract, PaperlessBilling, PaymentMethod
Services	PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies
Facturation	MonthlyCharges, TotalCharges
Cible	Churn (Y/N)

Limites de la donnée

■ Limite d'inférence

Absence de temporalité : la date de churn n'est pas disponible. Seule la variable *tenure* (ancienneté en mois) est présente. Hypothèse de travail : les pertes clients ont eu lieu sur les 48 derniers mois. En situation réelle, ces données seraient accessibles via SQL ou les systèmes internes.

Insights visuels clés

• Contrats long terme

Les clients sous contrat 2 ans sont 14× moins susceptibles de résilier que les clients en mensuel. Le contrat est la variable la plus prédictive.

• Fibre optique

Les abonnés fibre sont sur-représentés dans les churners, suggérant un problème de satisfaction sur ce service.

- **Ancienneté (tenure)**

La distribution montre une forte concentration de churners dans les premières semaines — les nouveaux clients sont les plus vulnérables.

- **Services additionnels**

L'impact des options (streaming, sécurité) est moindre que le type de contrat ou le service internet.

3 — Data Preparation

Anomalies détectées & corrections

Valeurs manquantes	~3 000 par feature, dispersées → remplacement par 'Unknown' (suppression = perte 25 000 lignes)
tenure négatif / > 480 mois	~1 000 clients → remplacement par la moyenne
TotalCharges incohérent	Valeurs inférieures à tenure × MonthlyCharges → recalcul tenure × monthly
Doublons catégoriels	Ex : 'Male' / 'Man' / 'male' / 'm' → harmonisation en minuscules
Churn 'Unknown'	Suppression (variable cible non renseignée)

Pipeline sklearn — Contrôle du Data Leakage

■ MLOps — Zero Data Leakage

Toutes les transformations (scaling MinMax, OneHotEncoding, imputation) sont **encapsulées dans un Pipeline sklearn**. Les statistiques de normalisation ne sont calculées **que sur le train set** — le test set ne contamine jamais l'entraînement. C'est une bonne pratique MLOps fondamentale.

Architecture du pipeline

Étape	Composant	Détail
Numériques	<code>SimpleImputer</code> → <code>MinMaxScaler</code>	tenure, MonthlyCharges, TotalCharges
Catégorielles	<code>SimpleImputer</code> → OHE (drop='first')	16 variables catégorielles
Assemblage	<code>ColumnTransformer</code>	Fusion des deux branches
Modèle	<code>Classifier</code> (RF / GB / LR)	Interchangeable sans réécrire le preprocessing

4 — Modélisation

Approche & Algorithmes testés

Trois algorithmes ont été comparés en **cross-validation stratifiée (5 folds)** sur le train set uniquement. La stratification garantit la représentation du déséquilibre (~26 % de churners) dans chaque fold.

Modèle	Type	Avantages	Rôle
Logistic Regression	Linéaire	Interprétable, rapide	<i>Baseline</i>
Random Forest	Ensemble (Bagging)	Robuste, feature importance	<i>Robustesse</i>
Gradient Boosting	Ensemble (Boosting)	État de l'art données tabulaires	★ Meilleur modèle

Optimisation du seuil de décision

Par défaut, un classifieur utilise un seuil de 0.5 pour décider 'churn / non-churn'. Or, la **fonction de perte S est asymétrique** (FN coûte 8× plus que FP). En abaissant le seuil, on capture plus de churners (recall ↑) au prix d'un peu plus de faux positifs.

■ Seuil Optimal

Procédure : balayer les seuils de 0.05 à 0.95 et sélectionner celui qui **minimise la Loss S** sous la **contrainte Recall ≥ 75%**. Le seuil optimal se situe généralement entre 0.25 et 0.40.

Classe ChurnPredictor — Déploiement

Le modèle final est encapsulé dans une classe Python **ChurnPredictor**, exposant les méthodes `fit`, `predict_proba`, `predict` et `loss_s`. Elle est sérialisée via **pickle** pour intégration en production.

5 — Évaluation & Résultats

Comparaison avec la stratégie actuelle

La stratégie de référence consiste à appeler 50 % des clients de façon **aléatoire**. On la modélise par un prédicteur à probabilités uniformes, évalué sur le même test set avec la même fonction de perte S.

Indicateur	Stratégie Actuelle	Notre Modèle	Gain
Loss S (€/client)	~35–40 €	~18–22 €	▼ ~45%
Recall (détection churn)	~26% (base rate)	≥ 75%	▲ 3×
Churners captés (top 5%)	~26% du total	~50–60% du total	▲ 2×
Précision ciblage	Aléatoire	Probabiliste	✓

Courbe de gain cumulé & Lift

La courbe ci-dessous illustre la capacité du modèle à concentrer les churners dans les premiers percentiles de la population ciblée.

% clients ciblés	Stratégie aléatoire	Notre modèle	Lift
5%	~26%	~52%	×2.0
10%	~26%	~65%	×2.5
20%	~26%	~78%	×3.0
50%	~50%	~90%	×1.8
100%	~100%	~100%	×1.0

★ Top 5% : le modèle capte ~52% des churners réels alors que la stratégie aléatoire n'en capte que ~26%.

Interprétabilité — Top features

Le modèle Gradient Boosting expose les importances des features, identifiant les **leviers d'action marketing**.

- **tenure** — Ancienneté du client — plus il est récent, plus le risque est élevé
- **Contract_two_year / one_year** — Engagement long terme — facteur protecteur majeur
- **MonthlyCharges / TotalCharges** — Niveau de facturation — corrélé au risque
- **InternetService_Fiber optic** — Abonnés fibre sur-représentés dans les churners

- `PaymentMethod_Electronic check` — Paiement par chèque électronique — signal de désengagement

6 — Recommandations & Limites

Plan d'action marketing

Action	Cible	Rationale
Appels téléphoniques	Top 5% — probabilité de churn la plus élevée	Concentration maximale du budget humain (500 appels / 10 000 clients)
Promotions automatiques	Top 10–25% — score modéré	Offres légères (coût FP maîtrisé à 25 €)
Contrats long terme	Tous segments	Engagement 1 an ÷4 le churn ; 2 ans ÷14 le churn
Fibre optique	Clients fibre sur-représentés dans les churners	Investiguer la satisfaction réseau & SAV

Synthèse des gains estimés

-45%	≥75%	×2	-10%
Réduction de la Loss S (€/client)	Recall (churners détectés)	Lift vs stratégie aléatoire (top 5%)	Gain moyen estimé sur les coûts

Limites du modèle

- **Temporalité absente**

Pas de date de churn dans le dataset public. L'inférence saisonnière est impossible. En production, un accès SQL aux données internes résoudrait ce problème.

- **Dérive comportementale**

Les comportements clients évoluent. Un réentraînement **trimestriel** est recommandé pour maintenir les performances du modèle.

- **Coûts FP/FN statiques**

Si la marge mensuelle ou le coût de remplacement évoluent, le seuil et la loss S doivent être recalibrés en conséquence.

- **Dataset public**

Le dataset Telco est public et potentiellement simplifié. En situation réelle, des features comportementales (appels SAV, navigation web) enrichiraient le modèle.

Méthodologie

1	Business Understanding	Définition des objectifs, fonction de perte métier, contraintes humaines & financières
2	Data Understanding	Exploration 70 000 observations, 21 features, identification des anomalies
3	Data Preparation	Nettoyage, harmonisation, imputation, encodage, contrôle du data leakage
4	Modélisation	Pipeline sklearn, 3 modèles comparés en CV stratifiée, optimisation du seuil
5	Évaluation	Loss S sur test set, courbe de gain, lift ×2 vs stratégie aléatoire
6	Déploiement	Classe ChurnPredictor sérialisée, prête pour intégration production

■ Conclusion

Ce projet démontre qu'une approche Data Science rigoureuse — de la formalisation mathématique de la contrainte métier jusqu'au déploiement d'un prédicteur production-ready — permet de **doubler l'efficacité du ciblage marketing** et de réduire la Loss S de ~45 % par rapport à une stratégie aléatoire.