

Réduire la perte clients par la Data Science

Classification binaire orientée ROI — Méthodologie CRISP-DM — Version corrigée du pipeline

53 / 47

répartition réelle Churn vs non-Churn (classes équilibrées)

70 000

observations dans le dataset

-28 %

coût moyen par client vs seuil par défaut

Table des matières

1

Business Understanding

Objectifs, contraintes métier, formalisation de la loss

2

Data Understanding

Exploration des données, qualité, classes réellement équilibrées

3

Data Preparation

Nettoyage, harmonisation, encodage, pipeline sans fuite de données

4

Modélisation

Seuil de Bayes théorique, comparaison de 3 modèles, cross-validation

5

Évaluation & Résultats

Matrice de confusion, coût moyen, gain réel mesuré

6

Recommandations & Limites

Plan d'action marketing, ce qu'il reste à valider

Contexte & Problématique

Problème Business

L'entreprise a perdu 53 % de ses clients sur les 4 dernières années, représentant une perte de revenus majeure. L'enjeu est d'identifier les profils à risque et de réduire ce taux en optimisant les coûts marketing.

Objectifs du projet

- Identifier les facteurs explicatifs du churn.
- Prédire les clients susceptibles de partir (classification binaire).
- Minimiser le coût moyen des erreurs, pas l'accuracy.
- Livrer un outil de ciblage utilisable par l'équipe marketing.

Fonction de perte métier

Plutôt qu'une métrique classique (accuracy, F1), le modèle est calibré sur une fonction de perte monétaire reflétant le coût réel de chaque erreur :

	Prédit : RESTE	Prédit : PART
Réalité : RESTE	0 €	Faux Positif — 25 €
Réalité : PART	Faux Négatif — 200 €	0 €

$R(g) = 25 \cdot nb(FP) + 200 \cdot nb(FN)$ — coût moyen attendu par client, minimisé sur le jeu de test.

Seuil de décision optimal — Théorème de Bayes

Avec des coûts asymétriques (FN = 8× plus coûteux que FP), le seuil de décision par défaut (0,5) d'un classifieur n'est pas optimal. Le seuil de Bayes théorique se déduit directement du rapport des coûts :

$$\text{seuil}^* = C_FP / (C_FP + C_FN) = 25 / 225 = 1/9 \approx 0,111$$

200 €

Coût d'un FN (churner manqué)

25 €

Coût d'un FP (offre à tort)

0,111

Seuil de Bayes théorique

Abaissier le seuil de 0,5 à 0,111 revient à accepter davantage de fausses alertes (peu coûteuses) pour ne presque plus rater de churners (très coûteux) — c'est la traduction directe de la contrainte métier dans le modèle.

Description du dataset

70 000

Observations clients

21

Features disponibles

53 / 47

Répartition Churn / non-Churn

0

Doublons détectés

Correction importante

L'analyse initiale supposait un fort déséquilibre de classes (~26 % de churners). Une exploration plus rigoureuse de la variable cible montre en réalité une répartition **quasi équilibrée (53 % churners / 47 % non-churners)**. Cette correction change la lecture du problème : pas besoin de technique de rééquilibrage (SMOTE, sur-échantillonnage...), le déséquilibre n'était qu'apparent.

Variables disponibles

- **Démographie** — gender, SeniorCitizen, Partner, Dependents
- **Compte** — tenure, Contract, PaperlessBilling, PaymentMethod
- **Services** — PhoneService, InternetService, OnlineSecurity, TechSupport, Streaming...
- **Facturation** — MonthlyCharges, TotalCharges

Insight clé confirmé

Le type de **contrat** reste, de loin, la variable la plus discriminante : parmi les churners, ~90 % sont sous contrat mensuel. Les contrats longs (1 an / 2 ans) séparent les classes presque parfaitement, ce qui explique pourquoi des modèles simples et complexes obtiennent ensuite des performances quasi identiques.

Nettoyage & pipeline sans fuite de données

Anomalie	Détail	Correction
Valeurs manquantes	~0,8 à 5 % par feature, dispersées sur toutes les lignes	Imputation (moyenne / médiane / mode) — pas de suppression
tenure négatif / = 999	~1 700 clients (erreurs de saisie évidentes)	Mise à NaN puis imputation par la moyenne
TotalCharges incohérent	Devises mélangées, valeurs < tenure × MonthlyCharges	Nettoyage de format + recalcul / mise à NaN si incohérent
Doublons catégoriels	Ex : 'Male' / 'Man' / 'm' / 'f'	Harmonisation en minuscules + mapping
Churn 'unknown'	Cible non renseignée	Suppression des lignes (apprentissage supervisé)

Correction MLOps — Split avant transformation

Le pipeline a été corrigé pour effectuer le **train/test split avant toute transformation non déterministe** : imputation, scaling (StandardScaler / RobustScaler) et OneHotEncoding sont fit uniquement sur le train, puis appliqués au test via ColumnTransformer + Pipeline sklearn — zéro fuite de données entre les deux jeux.

Approche & comparaison des modèles

Trois algorithmes ont été comparés en validation croisée stratifiée (5 folds), évalués sur le **coût moyen R(g)** et non sur l'accuracy.

Modèle	Coût moyen — seuil 0,5	Coût moyen — seuil de Bayes / pondéré	Coût moyen CV (5 folds)
1. Régression logistique classique	14,45 €	10,45 € (avec seuil 1/9)	14,52 €
2. Régression logistique pondérée retenu	—	10,45 €	10,52 €
3. Gradient Boosting	—	10,45 € (avec seuil 1/9)	14,53 €

Pourquoi le modèle le plus simple est retenu

La régression logistique pondérée (class_weight calé sur les coûts FP/FN) et le Gradient Boosting produisent des probabilités différentes, mais **1 seul désaccord de prédiction sur 13 990 clients test**. La variable Contract sépare quasiment parfaitement les classes : aucun individu proche du seuil de décision. Le modèle le plus simple et le moins coûteux en calcul est donc privilégié, sans perte de performance.

Gain réel mesuré sur le jeu de test

Matrice de confusion — seuil optimal (1/9)

n = 13 990 clients (jeu de test)

	Prédit : reste	Prédit : part
Réel : reste	VN = 2 630	FP = 4 800
Réel : part	FN = 131	VP = 6 429

Indicateurs clés

98 %

Recall (churners détectés)

-28 %

Coût moyen / client

Indicateur	Seuil par défaut (0,5)	Seuil optimisé (1/9)
Coût moyen / client	14,45 €	10,45 €
Faux négatifs	695	131
Recall	89 %	98 %

En recalibrant le seuil de décision sur la contrainte métier (et non sur 0,5 par défaut), le coût moyen par client passe de **14,45 €** à **10,45 €**, soit une **baisse de 28 %** du coût des erreurs de classification — confirmée par cross-validation à 5 folds (10,52 € vs 14,52 €).

Plan d'action & limites du modèle

Plan d'action marketing

Action	Cible
Appels téléphoniques	Clients avec probabilité de churn > seuil de Bayes (1/9)
Promotions automatiques	Score modéré — coût FP maîtrisé (25 €)
Contrats long terme	Tous segments — levier le plus fort identifié

Limites identifiées

- **Temporalité absente** — pas de date de churn dans le dataset public.
- **Variable Contract dominante** — la quasi-séparation parfaite des classes mérite d'être revalidée sur des données réelles, moins "propres" qu'un dataset pédagogique.
- **Coûts FP/FN statiques** — à recalibrer si la marge ou le coût de remplacement évolue.
- **Prochaine étape** — intégrer le seuil de décision directement dans la cross-validation (actuellement comparé hors CV) et tester une vraie courbe coût/seuil.

Conclusion

La correction du pipeline (split avant transformation, vraie répartition des classes, seuil calé sur le coût métier) confirme un gain réel : le coût moyen par client baisse de **28 %** par rapport à une décision au seuil par défaut, avec un modèle simple, rapide et facilement interprétable pour l'équipe marketing.