

HACKATHON

Dataack

Assistant IA
pour l'Actuariat

Milliman x Universite Gustave Eiffel
4-5 juin 2026

En 36 heures, construire un assistant IA
capable de repondre a des questions
techniques d'actuariat.

Approche RAG sur 150+ memoires d'actuariat

EQUIPE

ASMA Samy

FAGE Annaelle

LEUMEUNIER Ewann

KEREBEL Lea

PINA Ruben

huggingface.co/spaces/Dataack/My_App_Dataack

Le Defi

En 36h, construire un assistant IA pour répondre à des questions d'actuariat

Repondre juste, sans halluciner - pas cher, sobre

JUSTE

Accuracy

130 QCM + 20 ouvertes

PAS CHER

Cout

Tokens consommés (euro)


SOBRE

Carbone

CO2 estime via ecologits

Notre Pipeline RAG

De la question a la reponse sourcee en 6 etapes



Evaluation Interne

Mesurer la qualite avant le leaderboard

01

QCM & Questions ouvertes

Jeu d'evaluation cree par nos actuaires — questions issues directement des memoires, couvrant VIE, AUTO, MRH, Reassurance et Prevoyance.

02

Detection des hallucinations

Questions sans reponse dans le corpus intentionnellement inclues — le modele doit repondre 'je ne sais pas' plutot qu'inventer.

03

Score pondere (Excel)

Somme ponderee des criteres precision, cout et CO2 — permet de comparer les configurations de facon reproductible.

Chunking Semantique & Parallelisation

Mieux decouper, traiter plus vite

Chunking Semantique


Decoupage par sections logiques (titres, sous-titres)

- + Respecte la structure des memoires
- + Preserves les formules et tableaux
- + Passages complets et coherents
- + Moins de bruit dans le contexte LLM
- + Meilleure pertinence du retrieval

Parallelisation des Embeddings

Traitement simultane de tous les passages a indexer

Sequentiel :



Parallele :



Recherche Hybride : Vectorielle + BM25

Combiner similitude sémantique et correspondance exacte

Recherche Vectorielle

Similitude sémantique

- > Encode la question en vecteur
- > Compare par proximité cosinus
- > Trouve des concepts proches
- > Limite : rate les termes précis

BM25 (exact match)


Correspondance lexicale

- > Recherche par mots-cles exacts
- > Crucial pour termes techniques
- > 'SCR', 'IARD', 'provisionnement'
- > Complement indispensable

Les deux approches se combinent — les termes techniques précis ne passent plus au travers

Query Rewriting par LLM

Reformuler la question avant de chercher pour ameliorer le retrieval



Exemple concret

Originale : *Comment calcule-t-on le SCR en non-vie ?*



Enrichie : *Solvency Capital Requirement (SCR) calcul methodologie branche non-vie formule standard risque souscription*

Top-K Adaptatif selon la Complexite

Recuperer le bon nombre de passages — ni trop, ni trop peu

Question simple / QCM

Exemple :

Quelle est la definition du ratio de sinistralite ?

K = 3

Question precise, une seule source suffit. Moins de tokens, moins de CO2, reponse plus rapide.

Question complexe / ouverte

Exemple :

Comparez les approches de modelisation du risque climatique en assurance IARD.

K = 7

Raisonnement multi-sources necessaire. Plus de contexte ameliore la qualite de reponse.

Prompting - Framework COSTAR

Meilleur equilibre precision / CO2 / cout - teste et valide sur nos QCM



Contexte

Assistant actuarial - repond uniquement a partir du corpus fourni



Objectif

Repondre precisement, citer le passage source, eviter les hallucinations



Style

Technique, concis, structure - reference au memoire source



Ton

Professionnel, neutre, factuel



Audience

Actuaires experts - pas besoin d'expliquer les termes de base



Reponse

JSON strict : answer + sources + explanation

Sensibilite des parametres

parameter	value	acc_overall%	acc_gcm%	acc_open%	correct	total	avg_time_ms	tot_tokens	avg_tokens	tot_co2	avg_co2_g	temperature	max_tokens	reranking	top_k_ret	top_k_rer
baseline	baseline	90	97.3	0	36	40	6261	69627	1740.7	4.667	0.1167	0.1	1024	VRAI	20	5
temperature	0.05	92.5	100	0	37	40	5651	69945	1748.6	4.786	0.1197	0.05	1024	VRAI	20	5
temperature	0.3	87.5	94.6	0	35	40	5770	69715	1742.9	4.661	0.1165	0.3	1024	VRAI	20	5
temperature	0.7	90	97.3	0	36	40	5289	68973	1724.3	4.120	0.1030	0.7	1024	VRAI	20	5
temperature	1.5	92.5	100	0	37	40	5588	70183	1754.6	4.846	0.1212	1.5	1024	VRAI	20	5
max_tokens	512	90	97.3	0	36	40	5523	69134	1728.4	4.219	0.1055	0.1	512	VRAI	20	5
max_tokens	2048	90	97.3	0	36	40	5796	69801	1745.0	4.709	0.1177	0.1	2048	VRAI	20	5
enable_reranking	False	87.5	94.6	0	35	40	3814	68146	1703.6	4.113	0.1028	0.1	1024	FAUX	5	5
top_k_retrieval	5	87.5	94.6	0	35	40	4255	68185	1704.6	4.149	0.1037	0.1	1024	VRAI	5	5
top_k_retrieval	10	87.5	94.6	0	35	40	4391	70095	1752.4	4.151	0.1038	0.1	1024	VRAI	10	5
top_k_retrieval	15	90	97.3	0	36	40	4906	69400	1735.0	4.184	0.1046	0.1	1024	VRAI	15	5
top_k_reranked	1	87.5	94.6	0	35	40	5162	25164	629.1	3.578	0.0895	0.1	1024	VRAI	20	1
top_k_reranked	2	87.5	94.6	0	35	40	4827	36134	903.4	3.577	0.0894	0.1	1024	VRAI	20	2
top_k_reranked	3	85	91.9	0	34	40	5414	47470	1186.8	4.032	0.1008	0.1	1024	VRAI	20	3
top_k_reranked	7	90	97.3	0	36	40	5881	91149	2278.7	4.466	0.1117	0.1	1024	VRAI	20	7
top_k_reranked	10	90	97.3	0	36	40	6007	124503	3112.6	4.889	0.1222	0.1	1024	VRAI	20	10

Defis & Lecons Apprises

Ce que 36h sur un cas reel nous ont appris

Defis rencontres

- Qualite variable des PDF (OCR, tableaux)
- Equilibre top-k : precision vs cout
- Synchronisation ChromaDB sur HF Spaces
- Incident Git critique : gros probleme de commit en cours de hackathon
- Respecter strictement le contrat d'API

Lecons cles

- + La qualite du retrieval prime sur le choix du LLM
- + Tester l'endpoint tres tot (format strict)
- + Le routing petit/gros modele est tres efficace
- + Chunking semantique nettement > chunking fixe
- + Documenter les experiences au fil de l'eau

M E R C I

Des questions ?

Hackathon Milliman x
Universite Gustave Eiffel
4-5 juin 2026

Notre solution en un coup d'oeil

Retrieval hybride

BM25 + vectoriel + reranking sémantique

Routing intelligent

GPT-5.mini / GPT-5.1 selon la complexité

Prompt COSTAR

Reponses sourcees, anti-hallucination

Metriques integrees

CO2 (ecologits), tokens, latence